Multi-Probe Penetration Rate Study

프로브 차량 침투율에 따른 교통 밀도 추정 성능 분석

1. Car-Following으로 밀도를 왜 측정할 수 있는가

1.1 기본 원리

Car-following 이론(IDM, Gipps, Newell 등)에 의하면 차량의 가감속은 앞차와의 간격과 상대속도에 의해 결정된다:

$$a(t) = f\big(v(t),\ \Delta v(t),\ s(t)\big)$$

- v : 자차 속도
- Δv : 상대속도 (앞차 – 자차)
- s : 차간거리 (spacing)

이 함수에 s 가 포함되어 있으므로, 차량의 가감속 패턴에는 차간거리 — 즉 밀도 — 의 영향이 반영된다. 도로의 밀도가 높아지면:

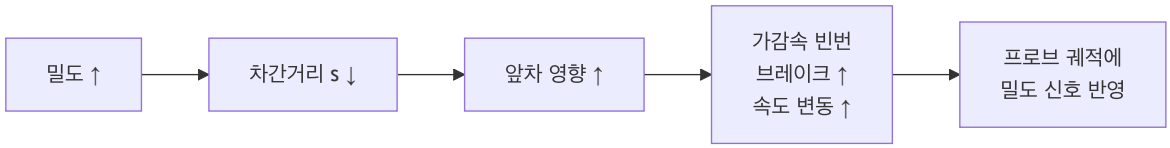

반대로 밀도가 낮으면 차간거리가 충분하여 앞차 영향이 없고, 차량은 자유주행 상태로 일정한 속도를 유지한다. 이처럼 **밀도에 따라 주행 거동이 달라지므로**, 프로브 궤적을 관측하면 밀도를 간접 추정할 수 있다.

아래 그림은 밀도에 따른 도로 상황과 개별 차량의 상태를 보여준다:

```
저밀도 (k=5):
  🚗          🚗              🚗          🚗
  free        free            free        free
  ├─ 차간거리 ~200m ─┤
  → 앞차 영향 없음. 모든 차량 자유주행. v ≈ v₀

중밀도 (k=12):
  🚗   🚗  🚗     🚗 🚗    🚗     🚗  🚗
  free  fol  fol    free fol   free    fol  fol
  ├─ ~80m ─┤
  → 일부 차량이 앞차를 추종. 자유주행/추종 혼재. 가감속 발생.

고밀도 (k=20):
  🚗🚗🚗🚗🚗🚗🚗🚗🚗🚗🚗🚗
  fol fol fol fol fol fol fol fol fol fol fol fol
  ├ ~50m ┤
  → 거의 모든 차량이 추종 상태. 지속적 가감속. 저속 주행.
```

1.2 ML을 사용하는 이유

프로브는 차간거리 s 나 주변 차량 수를 직접 관측하지 않는다. 관측 가능한 것은 자차의 **속도·가속도·브레이크** 뿐이다. 이 궤적 → 밀도 매핑은:

- **간접적**: 같은 가감속이 서로 다른 교통 상황에서 발생 가능
- **비선형**: 밀도와 거동의 관계가 구간별로 다름 (§1.3)
- **노이즈**: 운전자 이질성, 비평형 상태

이러한 **다변량 비선형 역문제**를 풀기 위해 ML을 사용한다. ML은 다채널 거동을 동시에 고려하여, 단일 변수(평균 속도) 기반 FD 역산보다 정밀한 밀도 추정이 가능하다.

1.3 밀도 구간별 추정 난이도

모든 밀도에서 동일하게 잘 되지는 않는다. 피처의 **신호 대 잡음비(SNR)** 가 구간별로 크게 다르다.

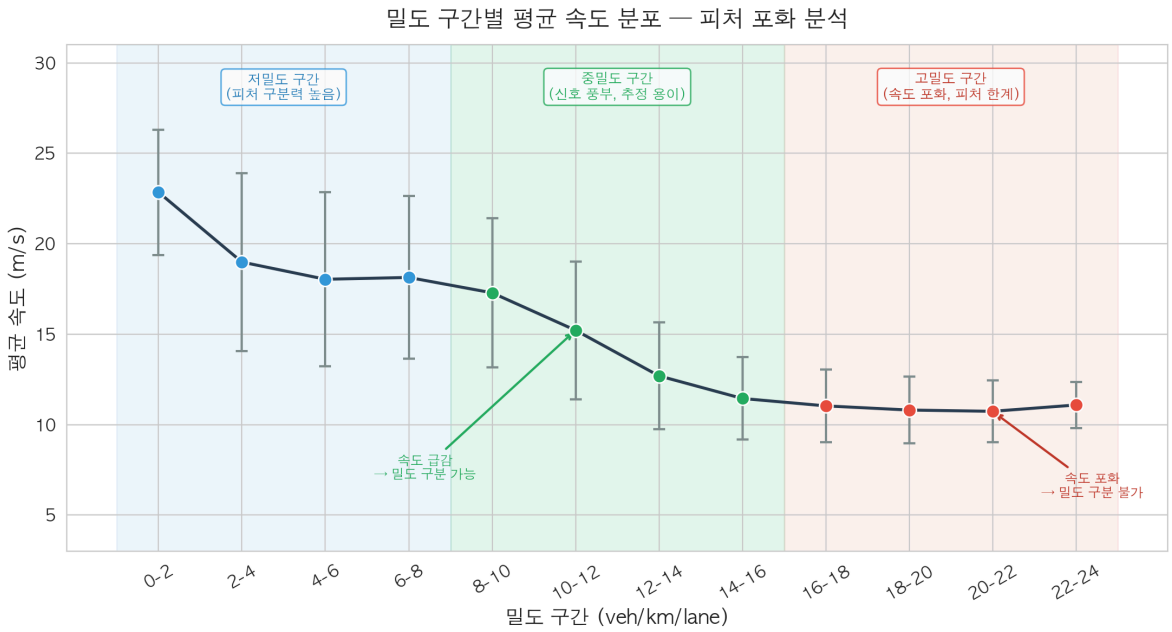

밀도 구간	CF 상태	추정 난이도	원인
저밀도 (0–8)	추종 거의 없음	어려움 (구조적)	$v \approx v_{free}$ 로 균일. 밀도 신호 부재
중밀도 (8–16)	추종 혼재	양호	피처 변별력 존재 (speed Δ2–4 km/h per 구간)
고밀도 (16–24)	전부 추종	어려움 (피처 포화)	$v \approx 11 \pm 2$ 로 밀도 내 변별력 소멸. 신호(Δ0.3) 대비 노이즈(±2.0) 과대

2. 다중 프로브: 왜 좋아지는가

2.1 단일 프로브의 관측 한계

밀도는 본질적으로 **공간적 양**(vehicles/km)이다. 단일 프로브는 자기 궤적이라는 **시간적 정보**만 관측한다.

시간 → 공간 변환에는 **에르고딕 가정**(정상·균일 교통류에서 시간 평균 = 공간 평균)이 필요하지만, 실제 교통류는 이를 만족하지 않는다. 1대는 자기 상태(자유주행 or 추종) 하나만 관측하므로, 도로 전체의 교통 상태 분포를 알 수 없다.

2.2 밀도와 추종 비율의 관계

§1.1의 CF 이론에서 보았듯이, 밀도가 높아지면 차간거리가 줄어들어 추종 상태에 진입하는 차량이 많아진다. 이 관계를 정량적으로 표현하면:

밀도 (veh/km/lane)	평균 차간거리	추종 차량 비율	도로 상태
5	~200 m	~20%	대부분 자유주행
8	~125 m	~40%	자유주행/추종 혼재 시작
12	~83 m	~65%	추종 위주, 간헐적 자유주행
15	~67 m	~85%	대부분 추종
20	~50 m	~95%	거의 전부 추종

밀도가 5에서 15로 3배 증가하면, 추종 비율은 20%에서 85%로 변한다. **추종 비율 자체가 밀도의 강한 지표**이다.

2.3 다중 프로브 = 추종 비율 샘플링

단일 프로브는 자기 상태 **1개**만 관측한다. 이것이 "자유주행"이면 도로 전체가 한산한지(k=3) 아니면 운이 좋아서 빈 공간에 있는 건지(k=10) 알 수 없다.

N대의 프로브가 있으면 **N개의 독립 샘플**을 얻어 추종 비율을 직접 추정할 수 있다:

```
k=5 (추종 비율 ~20%):
  프로브 5대 관측: free, free, free, free, fol  → 추종 1/5 = 20%  ✓

k=12 (추종 비율 ~65%):
  프로브 5대 관측: fol, free, fol, fol, fol    → 추종 4/5 = 80%  (오차 있지만 방향 맞음)

k=15 (추종 비율 ~85%):
  프로브 5대 관측: fol, fol, fol, fol, fol     → 추종 5/5 = 100% (오차 있지만 방향 맞음)
```

프로브가 많을수록 추종 비율 추정이 정확해진다. 단, 추정 오차는 $\propto 1/\sqrt{N}$ 으로 감소하므로, N이 커질수록 개선 속도가 둔화되어 자연스럽게 **포화**한다.

2.4 이론적 근거

개념	설명	본 연구와의 연결
Edie (1963)	q, k를 시공간 영역으로 정의	N대 = 더 큰 시공간 샘플링
Wardrop (1952)	$v_s = v_t - \sigma^2/v_t$	N대로 공간 속도 분산 직접 측정

개념	설명	본 연구와의 연결
에르고딕 가정	시간평균 = 공간평균 (정상·균일 조건)	N대면 이 가정 불필요
중심극한정리	표본 평균 오차 $\propto 1/\sqrt{N}$	추종 비율 추정 정밀도 개선

3. 구현

3.1 아키텍처

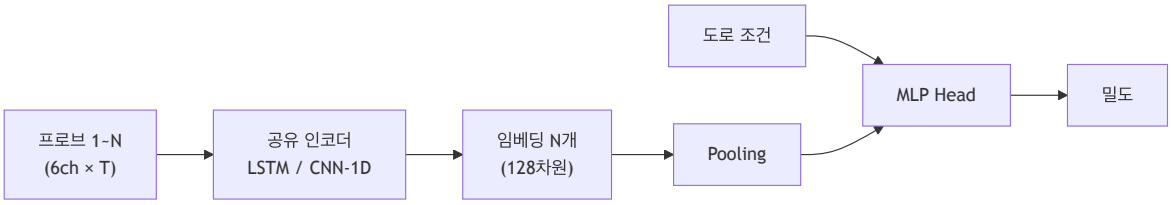

각 프로브의 6채널 × 100 타임스텝 시계열을 **동일한 인코더(가중치 공유)** 로 128차원 벡터로 압축한 뒤, Pooling으로 N개를 결합하여 밀도를 예측한다. 인코더는 시계열을 한 스텝씩 순서대로 읽으며 내부 상태를 갱신하고, 마지막 상태가 해당 프로브의 주행 패턴 요약(임베딩)이 된다. 가중치 공유는 모든 프로브를 동일한 분석기로 처리한다는 의미이다.

3.2 Pooling 방법

(a) Mean Pooling

$$\mathbf{h} = \frac{1}{N}\sum_{i=1}^{N}\mathbf{e}_i$$

모든 프로브 임베딩을 동등 가중 평균.

(b) Attention Pooling

각 프로브의 임베딩에 대해 **"이 프로브가 밀도 추정에 얼마나 유용한가"** 를 학습된 신경망이 자동으로 평가한다.

$$\alpha_i = \mathrm{softmax}\big(g(\mathbf{e}_i)\big), \qquad \mathbf{h} = \sum_{i=1}^{N}\alpha_i\,\mathbf{e}_i$$

학습 방법: 가중치 α_i 는 별도로 지정하지 않는다. 밀도 예측의 전체 손실(MSE)을 최소화하는 방향으로 역전파(backpropagation)를 통해 자동으로 학습된다. 즉, 밀도 추정에 유용한 패턴

을 가진 프로브에 자연스럽게 높은 가중치가 부여된다.

(c) CF-Score Weighted Pooling

Attention과 달리 **교통공학적 사전 지식**으로 가중치를 산출한다. 각 프로브의 원시 시계열에서 car-following 강도를 계산:

CF 지표	수식	의미
가속도 변동	$\sigma(a_{x,i})$	가감속이 잦을수록 추종 중
브레이크 비율	$r_{\text{brake},i}$	브레이크가 잦을수록 추종 중
속도 변동계수	$\text{CV}(v_i) = \sigma(v_i)/\bar{v}_i$	속도가 불안정할수록 추종 중

이 3개 지표를 결합하여 softmax 가중치를 산출:

$$w_i = \text{softmax}\big(\mathbf{a}^\top [\sigma(a_{x,i}),\ r_{\text{brake},i},\ \text{CV}(v_i)] \,/\, \tau\big)$$

$$\mathbf{h} = \sum_{i=1}^{N} w_i \, \mathbf{e}_i$$

의미: 추종 중인 프로브(가감속 크고, 브레이크 많고, 속도 불안정)에 높은 가중치를 부여. 자유주행 프로브(밀도 정보 부족)는 낮은 가중치.

3.3 XGBoost 비교 (Tabular)

DL과의 비교를 위해 N대 프로브의 엔지니어링 피처를 집계:

$$\bar{f}_k = \frac{1}{N}\sum_{i=1}^{N} f_{k,i}, \qquad s_k = \text{std}(\{f_{k,i}\}_{i=1}^{N})$$

피처별 평균 $\bar{f}_k$ 과 표준편차 s_k 를 XGBoost 입력으로 사용. 프로브 간 s_k 는 **공간적 변동**을 포착한다.

4. 결과

4.1 프로브 수에 따른 R^2

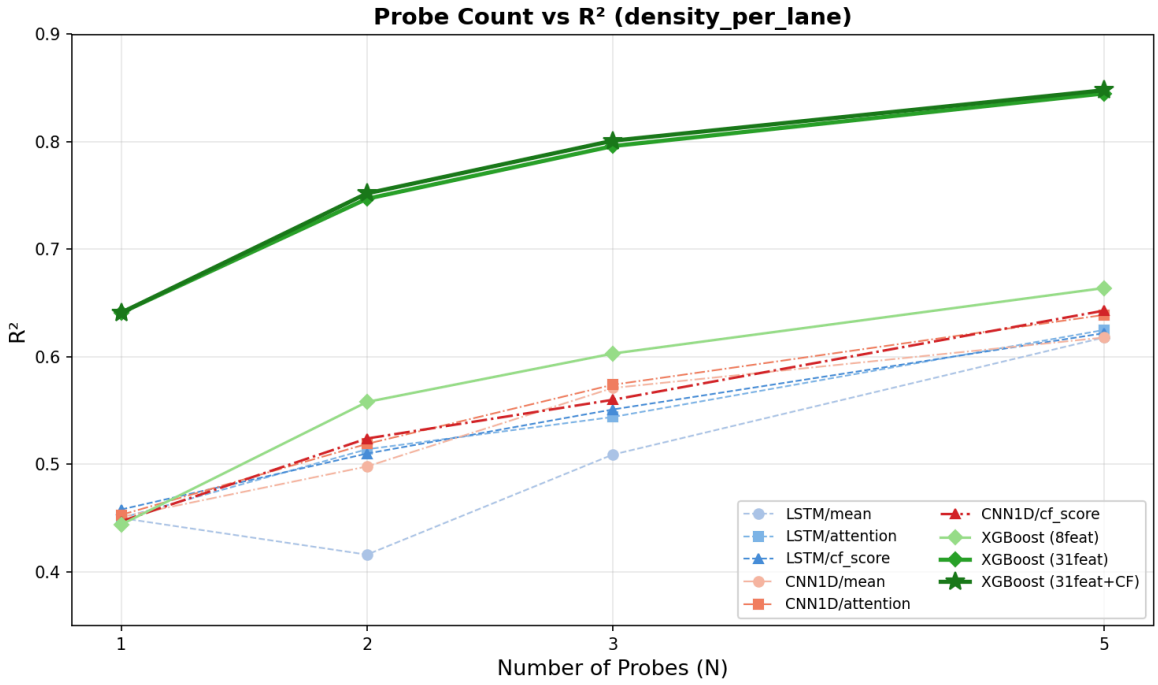

모델	N=1	N=2	N=3	N=5
LSTM / mean	0.450	0.416	0.509	0.618
LSTM / attention	0.450	0.514	0.544	0.625
LSTM / cf_score	0.458	0.510	0.551	0.622
CNN1D / mean	0.451	0.498	0.571	0.618
CNN1D / attention	0.453	0.519	0.574	0.639
CNN1D / cf_score	0.447	0.524	0.560	0.643
XGBoost (8피처)	0.444	0.558	0.603	0.664
XGBoost (31피처)	**0.641**	**0.747**	**0.796**	**0.845**
XGBoost (31피처+CF가중)	0.641	**0.752**	**0.801**	**0.848**

4.2 프로브 수에 따른 MAE

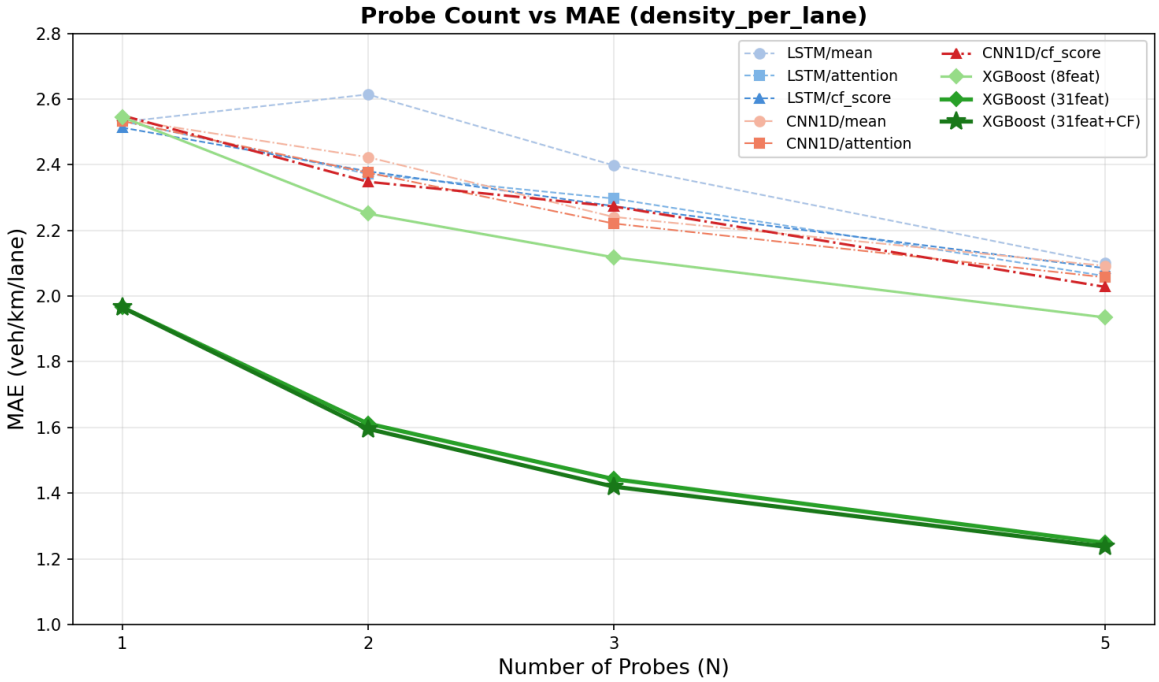

모델	N=1	N=2	N=3	N=5
LSTM / mean	2.530	2.614	2.398	2.100
LSTM / attention	2.533	2.372	2.297	2.061
LSTM / cf_score	2.513	2.380	2.274	2.085
CNN1D / mean	2.538	2.423	2.241	2.092
CNN1D / attention	2.533	2.376	2.221	2.057
CNN1D / cf_score	2.550	2.348	2.273	2.028
XGBoost (8피처)	2.545	2.251	2.118	1.935
XGBoost (31피처)	**1.966**	**1.612**	**1.443**	**1.249**
XGBoost (31피처+CF가중)	1.966	**1.596**	**1.420**	**1.237**

4.3 풀링 방법 비교

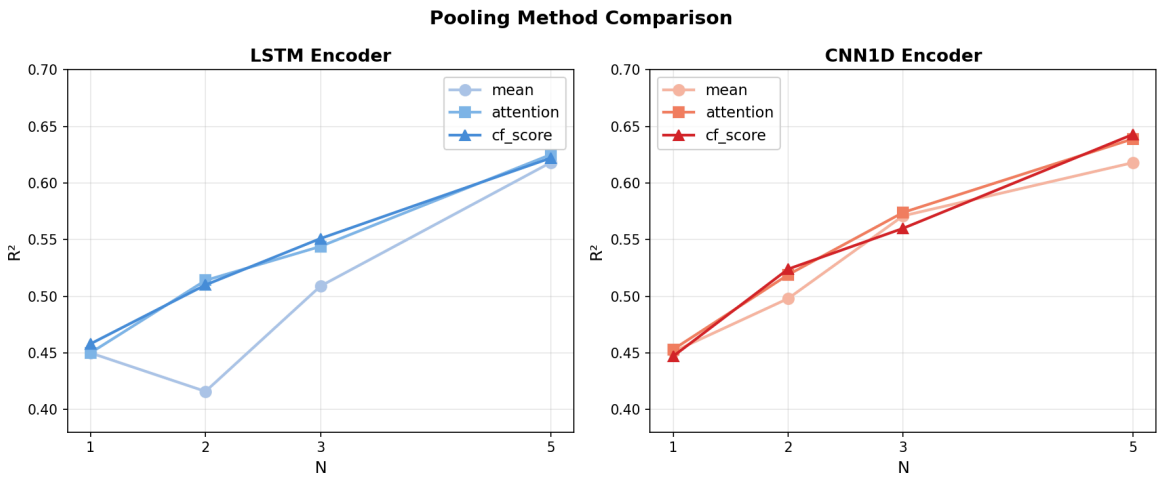

5. 분석

5.1 프로브 수 효과

모든 모델에서 프로브 수 증가에 따른 성능 개선이 관찰된다.

- **XGBoost**: R^2 0.444 → 0.664 (+0.22), MAE 2.55 → 1.94 (**–24 %**)
- **CNN1D / cf_score**: R^2 0.447 → 0.643 (+0.20), MAE 2.55 → 2.03 (**–20 %**)

N=3 → N=5 개선폭이 N=1 → N=2보다 작아지며, 이론적 $1/\sqrt{N}$ 포화 패턴과 일치한다.

5.2 CF-Score 가중치의 효과

CF-score 가중 풀링은 단순 평균(mean) 대비 개선을 보인다:

N	CNN1D / mean	CNN1D / cf_score	개선
2	0.498	0.524	**+0.026**
3	0.571	0.560	–0.011
5	0.618	0.643	**+0.025**

프로브가 여러 대일 때 자유주행/추종 프로브가 혼재하게 되며, **추종 중인 프로브(밀도 정보 풍부)에 높은 가중치를 부여하는 것이 유효**하다. N이 커질수록 이 혼재가 심해지므로 CF-score 가중치의 효과도 커질 것으로 예상된다.

5.3 DL vs XGBoost: 격차 축소와 역전 가능성

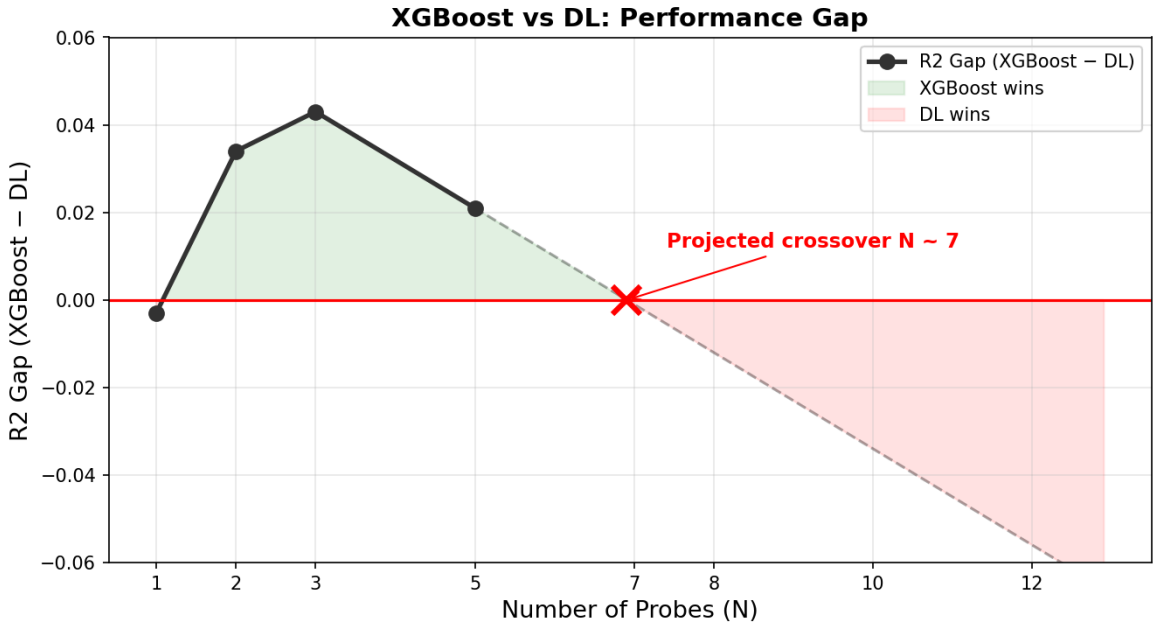

N	CNN1D / cf_score	XGBoost	격차
1	**0.447**	0.444	DL +0.003
2	0.524	**0.558**	XGB +0.034
3	0.560	**0.603**	XGB +0.043
5	0.643	**0.664**	XGB +0.021 ← **격차 축소**

현재 N=2~5에서는 XGBoost가 우세하다. XGBoost는 프로브 간 피처를 mean/std 2개 값으로 집계하는데, 소수 프로브에서는 이것이 효율적이기 때문이다.

그러나 **N=5에서 격차가 0.021로 급감**하고 있다. 이유:

- XGBoost: N대를 mean/std **2개**로 압축 → N이 커질수록 **정보 손실 증가**
- CNN1D/cf_score: N대 각각을 **128차원 임베딩**으로 유지 → N이 커져도 정보 보존

N > 5에서는 CNN1D/cf_score가 XGBoost를 **역전할 가능성이 높다**. 이를 검증하기 위해 시나리오당 프로브 10–20대를 추출하는 추가 실험이 필요하다.

6. 한계 및 향후 연구

1. **침투율 확장** — N > 5에서 DL/XGBoost 교차점 확인 (시뮬레이션 재실행, 프로브 10–20대)